

곤지암리조트 식음업장 수요예측 — 팀 브리핑 3편

DACON 236559 · LG AIMERS 7기 | 8월 4일 작업 결과 · 단순화 버전

2편 시점 Private 0.4439 (제출 v9)

현재 Private **0.43912** · 1등 0.437 과 0.0021 차이

이 문서의 범위 ① 성적이 어디서 올랐나 ② 지금 모델이 뭔가 ③ 어떻게 찾았나 ④ 왜 여기서 멈추나 ⑤ 이제 같이 생각할 것

기준 대회 최종 순위가 Private 기준이므로 이 문서의 점수는 전부 Private입니다. 낮을수록 좋습니다.

1. 시작 0.46068에서 0.43912까지 왔습니다(+0.02156). 그런데 그 개선의 83%가 모델을 전혀 건드리지 않고 나왔습니다. 모델 설정을 79가지 시험해서 얻은 건 17%뿐입니다.
2. 세 번의 도약은 전부 "평가식이 어떻게 생겼는지"에서 나왔습니다. 데이터에서 뭘 더 짜낸 게 아니라, 채점 공식의 성질을 이용한 겁니다.
3. 그리고 이제 자동 탐색으로는 더 안 오릅니다. 이론 하한을 재봤더니 겨울은 이미 한계에 도달했고, 봄에 남은 여지는 우리가 쓸 수 없는 정보(날씨) 뒤에 있습니다. 여기서부터는 같이 머리를 써야 하는 구간입니다.

1. 성적이 어디서 올랐나

제출 15건의 Private 점수를 시간순으로 놓고, 점수가 실제로 움직인 지점만 남긴 것입니다.

v1 0.46068 | 기준선 (7/30) | v8 0.45699 | ← 모델 튜닝 79개 설정 + 앙상블 7건 +0.0037 (17%) | v9 0.44386 | ← ★ 3구간 후보정 +0.0131 (61%) | v12 0.44123 | ← ★ 기하 정수 스냅 +0.0026 (12%) | v18 0.43912 | ← ★ 임계 조정 (2.0 → 1.8) +0.0021 (10%) | └─ 합계 +0.02156

개선의 출처	개선폭	비중	무엇을 했나
모델	+0.00370	17%	하이퍼파라미터 79개 탐색 · XGBoost/CatBoost 비교 · 앙상블 7건
후처리 (★ 3건)	+0.01787	83%	학습을 한 번도 다시 하지 않았습니다. 이미 만들어진 예측값에 산수만 엮었습니다.

여기서 얻을 교훈

모델을 좋게 만드는 데 며칠을 썼고 얻은 게 17%입니다. 반면 "채점이 어떻게 되는지"를 들여다보고 거기 맞춰 출력을 손본 것이 83%였습니다. 그리고 후처리 셋은 각각 몇 분이면 끝나는 작업이었습니다 — 저장해 둔 예측 파일에 곱하기 한 번씩입니다.

참고: 손해 본 시도들

올라간 것만 보면 균형이 안 맞으니, 내려간 것도 같이 남깁니다.

시도	Private 변화	왜 실패했나
보정값 재적합 (v11)	-0.00596	내부 검증이 "이게 더 낫다"고 해서 이미 검증된 값을 갈아치웠는데 틀렸습니다.
모델 용량 확대 (v4)	-0.00509	내부 검증 1등이었는데 실제로는 꼴찌였습니다.
보정을 낮은 구간에만 (v10)	-0.00342	덜 하는 게 더 나을 거라 봤는데 아니었습니다.
모델 3종 앙상블 (v16)	-0.00102	작은 모델을 섞으니 오히려 나빠졌습니다.

공통점

실패한 넷은 전부 "내부 검증 점수가 좋아져서" 낸 것입니다. 성공한 셋은 전부 이론에서 유도했거나 조절할 숫자가 0~1개였습니다. 2편에서 다룬 "내부 검증이 실제 순위를 거꾸로 예측한다"는 문제가 계속 살아 있습니다.

2. 지금 우리 모델이 무엇인가

2-1. 대회 평가식 (정확한 형태)

$D_i = \{ t : A(t,i) \neq 0 \}$ ← 실측이 0이 아닌 날짜만 모은다. 0인 날은 채점 제외
 $T_i = |D_i|$ ← 그 개수

① 품목 i 의 점수

$$S_i = (1 / T_i) \cdot \sum_{t \in D_i} \frac{2 |A(t,i) - P(t,i)|}{|A(t,i)| + |P(t,i)|}$$

② 영업장 s 의 점수

$$S_s = (1 / |I_s|) \cdot \sum_{i \in I_s} S_i \quad \leftarrow \text{품목끼리 균등}$$

③ 최종

$$\text{Score} = \sum_s w_s \cdot S_s$$

s : 영업장 (9곳) I_s : 그 영업장의 품목 집합
 w_s : 영업장 가중치 (비공개, 담하·미라시아가 높다고만 공지됨)
 A : 실측, P : 예측. 낮을수록 좋다.

세 번 평균합니다. ① 품목 안에서 유효 날짜끼리 → ② 영업장 안에서 **품목끼리 균등** → ③ 영업장끼리 가중합.

②가 이 대회의 성격을 정합니다

한 영업장 안에서 **품목은 유효 날짜 수와 무관하게 1표씩**입니다. 유효 날짜가 9개뿐인 희귀 품목이 28개짜리 주력 품목과 동등합니다.

그래서 **영업장마다 품목 1개의 무게가 다릅니다** — 품목 5개인 화담숲카페는 하나가 **2.222%**, 품목 42개인 담하는 하나가 **0.265%**로 **8.4배** 차이입니다.

2-2. 그 벌점의 정제 — 여기서 나머지가 전부 따라 나옵니다

안쪽 항 하나만 떼어 보겠습니다. **비율** $r = A / P$ 로 바꿔 쓰면 이렇게 정리됩니다.

$$\frac{2 |A - P|}{|A| + |P|} = \frac{2 |r - 1|}{r + 1} = 2 \cdot \tanh(|\ln(A/P)| / 2)$$

수치 확인 (무작위 20만 쌍) : 최대 오차 6.7×10^{-16} → 근사가 아니라 항등식
검산 $A=5, P=1$: $2 \cdot 4/6 = 1.33333 = 2 \cdot \tanh(\ln 5 / 2) = 1.33333$

즉 **SMAPE 벌점은 "예측이 몇 배 틀렸는가"의 함수**입니다. 절대 오차가 아니라 **배수 오차**만 봅니다. 여기서 세 가지가 바로 따라옵니다.

#	따름정리	확인
1	배수에 대칭이다. $\tanh$ 안이 $ \ln r $ 이므로 r 과 $1/r$ 의 별점이 정확히 같다. 5배 과대예측과 5배 과소예측이 동일한 별점입니다.	$\phi(0.2) = \phi(5) = 1.33333$
2	오차가 작으면 별점 $\approx \ln(A/P) $. $\tanh(x) \approx x$ 이므로. $\rightarrow$ 로그를 씌운 뒤 절대오차 (L_1)를 줄이는 것이 곧 이 지표를 줄이는 것입니다.	$A/P=1.1$ 일 때 실제 $0.09524 \cdot \ln 0.09531$
3	별점 상한은 2. $\tanh$ 가 1로 수렴하므로. 전부 0으로 예측하면 정확히 2.0(최악)이 나오는 이유입니다.	1편에서 실측한 값과 일치

2-3. 학습 목적함수 (정확한 형태)

학습에 쓰는 행 : $y \neq 0$ 인 행만. 음수(환불)는 1로 치환.
 $\rightarrow$ 전체 약 32만 행

목적함수 : $\min_f \sum_{i: y_i \neq 0} |\ln(1 + y_i) - f(x_i)|$

예측 복원 : $P = \exp(f(x)) - 1 \quad \leftarrow$ 그 다음 2-5의 후처리

왜 하필 "log를 씌우고 L_1 "인가 — 2-2의 따름정리 2가 근거입니다

별점이 $2 \cdot \tanh(|\ln(A/P)|/2)$ 이고 이걸 $|\ln A - \ln P|$ 의 증가함수입니다. 그러니 로그 공간에서 절대오차를 줄이는 것이 지표와 정렬됩니다.

※ $\ln(1+y)$ 의 +1은 $y=0$ 을 다루기 위한 관례인데, 우리는 어차피 $y \neq 0$ 행만 쓰므로 형태를 맞추는 역할만 합니다.

※ L_1 (절대오차)은 조건부 중앙값을 추정합니다. L_2 (제곱오차)를 쓰면 평균을 추정하는데, 수요 분포가 오른쪽으로 길게 늘어져 있어(평균 22.8 > 중앙값 4) 평균은 지표와 안 맞습니다. 실제로 L_2 -Huber는 시험해봤고 더 나빴습니다.

2-4. 검증을 어떻게 나눴나 — 무작위로 나누면 안 됩니다

보통 하듯 데이터를 무작위로 8:2로 갈라 쓸 수 없습니다. 이유가 셋입니다.

1. 미래가 과거로 셉니다. 시계열이라 뒤 날짜가 학습에 들어가면 앞 날짜를 맞히는 게 반칙이 됩니다.
2. 같은 날짜가 양쪽에 들어갑니다. 우리 학습 행 하나는 "어떤 28일 창 $\rightarrow$ 그 다음 7일"인데, 창은 서로 겹칩니다. 무작위로 나누면 검증 행의 답이 학습 행의 창 안에 들어 있게 됩니다.
3. 실제 과제의 모양이 다릅니다. 대회는 학습 종료 후 0~11개월 뒤를 맞히라고 합니다. 무작위 분할은 이 "거리"를 재현하지 못합니다.

그래서 시간을 기준으로 자릅니다(rolling origin). 어느 날짜까지만 학습시키고, 그 이후 구간에서만 채점합니다.

학습 데이터 전체 : 2023-01-01 ~ 2024-06-15 (532일)

실제 제출 모델 : 위 전체로 학습 $\rightarrow$ 2024-06-16 ~ 2025-05-31 (1년) 예측

폴드	학습 종료	학습 행 수	검증 구간	거리
F2 겨울	2023-11-23	185,335	2023-11-24 ~ 2024-02-22	0개월
F3 봄	2024-02-22	255,834	2024-02-23 ~ 2024-06-08	0개월
FAR-봄	2023-11-23	185,335	2024-02-23 ~ 2024-06-08	3개월
FAR-겨울	2023-08-24	118,996	2023-11-24 ~ 2024-02-22	3개월
(실제 제출)	2024-06-15	320,012	2024-06-16 ~ 2025-05-31	0~11개월

왜 "FAR" 폴드를 따로 만들었나

앞의 둘(F2-F3)은 학습이 끝난 직후를 맞힙니다. 그런데 실제 채점은 최대 11개월 뒤입니다. 2편에서 다룬 대로, 이 차이 때문에 내부 검증이 실제 순위를 거꾸로 예측한 적이 있습니다. 그래서 학습량은 그대로 두고 검증 시점만 3개월 뒤로 민 폴드를 둘 더 만들었습니다.

이번에 발견한 것 — 폴드 4개는 사실 독립 2개입니다

표를 다시 보면 F2와 FAR-겨울의 검증 구간이 같고(2023-11-24~2024-02-22), F3와 FAR-봄의 검증 구간도 같습니다(2024-02-23~2024-06-08). 학습 종료 시점만 다릅니다.

따라서 "4폴드에서 전부 같은 방향"은 실제로는 "독립 2구간에서 2회 일치"로 읽어야 합니다. 지금까지 일관성을 실제보다 후하게 읽고 있었습니다.

※ 가을 폴드(F1)도 있었으나 학습량이 실제의 42%뿐이라 판단을 오염시켜 폐기했습니다.

2-5. 예측 후처리 (개선의 83%가 여기)

모델 원본 예측 $p = \exp(f(x)) - 1$

① 구간별 배율

$p < 1.8 \rightarrow \times 0.55$
 $1.8 \leq p < 10 \rightarrow \times 0.90$
 $p \geq 10 \rightarrow \times 1.02$

② 하한

$\max(\cdot, 1.0)$ ← 채점 대상은 전부 $|A| \geq 1$ 이므로 1 미만은 항상 손해

③ 정수 스넵

가장 가까운 정수로. 경계는 $\sqrt{k(k+1)}$
 $(1 \leq 2 \text{ 는 } 1.4142, \quad 2 \leq 3 \text{ 은 } 2.4495, \quad 9 \leq 10 \text{ 은 } 9.4868)$

결과 : 전체 칸의 33%가 정확히 1.0 • 100%가 정수

2-6. 모델 설정

LightGBM 1개 (전 영업장·전 품목 통합. 영업장별로 나누지 않음)

num_leaves 127 • feature_fraction 0.65 • min_data_in_leaf 40

bagging_fraction 0.85 • lambda_l2 1.0 • learning_rate 0.05 • 1000 rounds

피쳐 57개 • 서로 다른 난수 시드 5개로 학습해 평균

영업장별·horizon별로 모델을 쪼개보는 것은 시험했고 7/7로 통합 모델이 이겼습니다. 트리가 store·horizon 을 뿌리에서 이미 갈라치고 있어서, 나누면 학습량만 잃습니다.

2-7. 왜 "실측 0인 행을 빼는가"

평가식(2-1)의 d_i 가 실측이 0이 아닌 날짜만 모읍니다. 즉 0인 칸은 아예 채점되지 않습니다. 그래서 우리 문제는 "이 메뉴가 팔릴까"가 아니라 "팔린다면 몇 개일까"입니다. 학습에서 0을 빼는 것만으로 점수가 0.895 → 0.543으로 갔습니다. 이 대회 단일 최대 개선이며 1편에서 다룬 내용입니다.

3. 세 번의 도약을 어떻게 찾았나

팀원들이 가장 궁금해할 부분이라 생각해서 따로 썼습니다. 셋 다 "모델을 어떻게 고칠까"가 아니라 "채점 공식이 무엇을 원하는가"를 물어서 나왔습니다.

① 3구간 후보정 (+0.0131) — 예측이 안쪽으로 몰려 있었다

예측값을 크기순으로 10등분하고, 구간마다 "몇 배를 곱해야 가장 점수가 좋은가"를 따로 재봤습니다. 그랬더니 방향이 구간마다 반대였습니다.

예측 구간	실측 중앙값	예측 중앙값	최적 배율	해석
0.63 ~ 1.44	1.0	1.19	0.60	과대예측
5.72 ~ 9.49	7.0	7.16	1.00	맞음
19.6 ~ 46.2	36.0	30.05	1.17	과소예측

작은 건 크게 부르고, 큰 건 작게 부르고 있었습니다. 예측이 가운데로 눌러 있었던 거죠. 그래서 전체에 같은 숫자를 곱하는 방법(전역 배율)은 안 통했던 겁니다 — 방향이 반대인 것들이 서로 상쇄되니까요. 구간을 셋으로 나눠 각각 다른 배율을 주니 +0.0131이 나왔습니다.

② 정수 스냅 (+0.0026) — 실측은 항상 정수다

이게 가장 깔끔한 발견입니다. 맞출 숫자가 하나도 없습니다. 2-2에서 본 항등식에서 두 단계로 유도됩니다.

단계 1 — 두 정수 사이는 항상 손해다

별점이 $2 \cdot \tanh(|\ln(A/P)|/2)$ 이고, 실측 A는 항상 정수입니다. 그러면 확률질량이 정수에만 놓이므로, 예측을 두 정수 사이에 두면 양쪽 어디에도 못 맞히면서 별점만 받습니다.

실측이 1 아니면 2 (반반)일 때	예측 1	예측 1.5	예측 2
기대 별점	0.3333	0.3429	0.3333

가운데가 더 나쁩니다. 그러니 예측을 정수로 옮기면 손해 볼 일이 없습니다.

단계 2 — 그런데 경계가 1.5가 아니다

1과 2 중 어디로 옮길지, 그 갈림길이 어디냐가 문제입니다. 별점이 $|\ln A - \ln P|$ 의 함수이므로 거리를 로그 자로 재야 합니다. 로그 자에서 중간 지점은:

$\ln P = (\ln k + \ln (k+1)) / 2$	→	$P = \sqrt{ k (k+1) }$
1 ↔ 2 경계 = $\sqrt{2}$ = 1.4142		(산술중점 1.5 가 아님)
2 ↔ 3 경계 = $\sqrt{6}$ = 2.4495		
9 ↔ 10 경계 = $\sqrt{90}$ = 9.4868		

이론이 데이터에서 확인됐습니다

검증에서 산술 반올림(경계 1.5)은 +0.0015, 기하 경계(1.4142)는 +0.0028로 같았습니다. 거의 두 배 차이입니다.

한 폴드에서는 산술 반올림이 -0.0017로 손해인데 기하 경계는 +0.0052로 이득이었습니다. 맞춰서 얻은 게 아니라 유도해서 맞은 것이라 이 측은 뒤집힐 걱정이 없습니다.

③ 임계 조정 (+0.0021) — ②가 새 레버를 드러냈다

정수 스냅을 켜고 나니 재미있는 일이 생겼습니다. 1구간 배율 0.55가 아무 의미가 없어졌습니다.

0.55 를 곱하고 → 하한 1을 곱고 → 정수로 스냅하면

예측 < 1.8 인 칸은 무엇을 곱하든 전부 정확히 1.0이 된다.

실제로 확인: 배율 0.30 / 0.40 / 0.55 / 0.65 / 0.70 → 소수점 6자리까지 완전히 동일

배율 0.75 부터 갈라짐 ← 이론값 $\sqrt{2} \div 2 = 0.7071$ 과 정확히 일치

그러면 남은 조절 손잡이는 배율이 아니라 "어디까지를 그냥 1로 찍을 것인가"라는 경계값 하나입니다. 그 경계를 2.0에서 1.8로 내리니 +0.0021이 나왔습니다.

그리고 이건 요행이 아닙니다 — 1.70부터 1.90까지가 통째로 고원이고 양옆으로 떨어집니다. 최고점 하나만 튀는 게 아니라 넓게 퍼져 있으면 진짜 효과라고 봅니다.

4. 왜 여기서 멈추나 — 이론 하한

4-1. 먼저 질문 하나 — "완벽한 예측"이 될까요

보통 "실제 팔린 개수를 정확히 맞히는 것"이라고 생각합니다. 그런데 **그건 애초에 불가능합니다**. 실제 팔린 개수 자체가 매번 달라지기 때문입니다.

실제 데이터를 보시죠. **담하 들깨양지탕, 금요일, 5주 연속**입니다.

8개 · 4개 · 9개 · 9개 · 4개

같은 메뉴, 같은 요일, 연달아 5주입니다. 조건이 거의 똑같은데 **4개에서 9개까지 두 배 넘게 차이납니다**.

이제 상상해 봅시다. **신이 와서 "이 메뉴의 금요일 진짜 평균은 6.8개다"**라고 정답을 알려줬습니다. 그래서 매주 6.8로 예측했습니다. 벌점이 0일까요?

그 주 실제	8개	4개	9개	9개	4개	평균
예측 6.8 의 벌점	0.162	0.519	0.278	0.278	0.519	0.351

정답을 완벽하게 알아도 0.351 이 남습니다. 이게 이론 하한입니다.

왜 남는가 — SMAPE는 2장에서 본 대로 **"몇 배 틀렸나"**를 봅니다. 실제값이 평균 주변에서 흔들리면 **그 흔들림만큼은 무조건 틀립니다**. 실력 부족이 아니라 그냥 수요가 그렇게 생긴 겁니다.

비유하면 주사위 눈 맞히기입니다. 아무리 머리가 좋아도 "3.5"라고 부르는 게 최선이고, 그래도 매번 틀립니다. 그 틀림은 실력 문제가 아니라 주사위의 성질입니다.

4-2. 전체 데이터로 재봤습니다

같은 방식으로 **품목 × 요일 × 연속 5주** 조합을 전부 뽑았습니다. **21,611개**입니다.

실제 판매량의 흔들림 (표준편차 ÷ 평균)
중앙값 **52%** 사분위 37% ~ 69%

"평균을 완벽히 알아도 남는 벌점"
중앙값 **0.415** 평균 **0.441**

우리 실제 성적
겨울 **0.4353** 봄 **0.4813**

실제 판매량이 자기 평균 대비 **절반쯤 흔들립니다**. 그리고 그 흔들림만으로 계산한 하한이 **0.44 근처**인데, **우리 겨울 성적이 0.4353**입니다.

품목마다 하한이 다릅니다

품목 (같은 요일 5주)	실제 5주	흔들림	완벽해도 남는 벌점
담하 은이버섯 갈비탕 (수)	4 · 1 · 4 · 8 · 18	95%	0.721
담하 갑오징어 비빔밥 (일)	4 · 5 · 12 · 11 · 23	69%	0.495
포레스트릿 스프라이트 (수)	64 · 21 · 34 · 24 · 16	60%	0.418
담하 들깨양지탕 (금)	8 · 4 · 9 · 9 · 4	38%	0.351

흔들림이 큰 품목일수록 하한이 높습니다. 은이버섯 갈비탕은 4개에서 18개까지 오가니 아무리 잘해도 0.721 밑으로 못 갑니다.

여기서 앞의 수수께끼가 풀립니다

"우리가 가장 못하는 품목" 1위가 **담하 갑오징어 비빔밥(0.880)**이었습니다. 그런데 그 품목의 하한이 **0.495**입니다. 우리가 못하는 게 아니라 그 메뉴가 원래 그렇게 튀는 겁니다.

4-3. 그래서 계절별로 얼마나 남았나

검증 구간	이론 하한	우리 성적	판정
겨울	0.4265 ~ 0.4495	0.4353	이미 하한 범위 안 — 사실상 한계 도달
봄	0.4310 ~ 0.4528	0.4813	0.03 ~ 0.05 남음

겨울은 신이 와서 정답을 알려줘도 지금보다 별로 안 나아진다는 뜻입니다. 봄은 아직 여지가 있습니다.

※ 하한이 범위인 이유: 위 예시는 "평균으로 예측했을 때"인데, 2장에서 봤듯 SMAPE는 평균보다 살짝 아래를 좋아합니다. 그 최적화까지 넣어 계산하면 하한이 조금 더 내려가므로 폭을 두었습니다.

그런데 그 남은 여지가 어디 있냐면

"완전한 정보를 준다면 얼마나 좋아지나"를 축별로 계산해봤습니다.

어떤 정보를 완전히 준다면	겨울	봄
영업장별 그날의 총 판매량	+0.1059	+0.1346
영업장별 그 주의 총 판매량	-0.0814	-0.0243

여지가 전부 "그날" 속에 있습니다. 주 단위는 완전한 정보를 줘도 오히려 손해입니다 — 이미 다 쓰고 있다는 뜻이죠.

그럼 "그날"이 도대체 뭔가. 야외 영업장들의 일별 오차가 서로 얼마나 닮았는지 봤습니다.

포레스트릿 ↔ 화담숲주막	0.61
포레스트릿 ↔ 화담숲카페	0.66
화담숲주막 ↔ 화담숲카페	0.83
실내 영업장끼리	0.23 ~ 0.41
느티나무 · 연회장	거의 0

공통 요인 하나가 야외 영업장을 지배하고 있습니다 — 날씨로 보입니다

그리고 이건 이중으로 막혀 있습니다.

- ① 대회 규칙상 외부 데이터(날씨 포함) 사용 금지
- ② 설령 알아도 채점할 때 그날 다른 영업장 판매량을 볼 수 없습니다 — 7일치를 한꺼번에 예측하니까요

그래서 시도해본 회수 방법들

"그날 축"에 못 닿으니 우회로를 찾아봤습니다. 전부 실패했습니다.

방법	자기 데이터에서	교차검증에서
품목마다 다른 배율을 주기	+0.031 ~ +0.041	8건 전부 마이너스
성적 나쁜 품목만 배율 조정	+0.0014	-0.0086 (부호 반전)
단체 메뉴만 따로 보정	+0.00055	잡음과 구분 불가

※ 교차검증 = 일부 구간에서 값을 정하고 다른 구간에서 채점하는 것. 같은 데이터에서 정하고 같은 데이터로 채점하면 항상 좋게 나오므로 분리합니다.

한 가지 확인해둘 것 — 우리 모델은 이미 "미래를 훑쳐보는" 기준을 이깁니다

실측을 보고 같은 요일 ±4주를 평균낸 것이 0.597 / 0.561, 국소 ±3일이 0.561 / 0.580, 둘을 합쳐도 0.490 / 0.510인데 우리 모델은 0.435 / 0.481입니다. 정답을 일부 보고 만든 것보다 우리가 낫습니다.

5. 이제 같이 생각해야 할 것

여기까지는 "시키면 하는" 방식으로 갈 수 있는 끝이라고 봅니다. 자동으로 설정을 훑고 검증 점수가 좋은 걸 고르는 방식은 소진됐습니다. 남은 문제들은 이론을 들여다보고 판단해야 하는 것들이라 팀에서 같이 봤으면 합니다.

Q1 날씨를 대신할 "합법적인" 신호가 데이터 안에 있는가?

여지가 날씨에 있는데 날씨는 못 씁니다. 그런데 주어진 데이터 안에 날씨의 그림자가 남아 있을 수는 있습니다. 예를 들어 28일 창 안의 야외 영업장 판매 패턴 자체가 그 기간 날씨를 반영합니다. 문제는 예측해야 할 7일의 날씨인데 그건 창에 없습니다.

→ 생각해볼 것: 창 안 정보만으로 "다음 주가 좋은 날씨일 확률"에 접근할 방법이 있는가? 계절·기압 주기 같은 물리적 규칙성을 쓸 수 있는가? 아니면 이건 원리적으로 불가능한가?

Q2 겨울은 한계인데 봄은 왜 0.03~0.05가 남았는가?

같은 모델인데 두 계절의 성적이 하한 대비 완전히 다릅니다. 봄에는 화담숲 재개장(3월 말)과 스키장 폐장이 겹칩니다. 즉 영업 상태가 바뀌는 전환기입니다.

→ 생각해볼 것: 이건 "예측이 어려운 것"인가, 아니면 "전환을 우리가 못 알려주고 있는 것"인가? 우리는 개장일을 상수로 넣어봤는데(실제 개장은 3/29~31), 이걸 창에서 읽어내게 하는 방법이 있는가?

Q3 평가식의 가중 구조를 더 쓸 수 있는가?

영업장 9곳이 균등하게 1/9씩 가중되고, 그 안에서 품목이 균등합니다. 그래서 품목 1개의 무게가 영업장마다 8.4배 차이납니다.

영업장	품목 수	품목 1개의 가중
화담숲카페	5	2.222%
화담숲주막	8	1.389%
포레스트릿	12	0.926%
담하	42	0.265%

1등과의 차이 0.0021은 화담숲카페 품목 하나를 0.095 개선하는 것과 같습니다. 담하로 하려면 0.79를 개선해야 합니다.

→ 그런데 알갭게도 그 소형 영업장 셋이 정확히 날씨에 묶인 야외 업장입니다. 표적이 있는 곳과 길이 없는 곳이 같습니다. 이 구조를 다르게 쓸 방법이 있는지 같이 봤으면 합니다.

Q4 아직 설명 못 한 현상이 하나 있습니다

Public과 Private 점수 차이가 우리는 **0.0137**인데 상위권 팀들은 **0.003** 정도입니다. 4~5배 차이입니다. 더 이상한 건, 모델을 전혀 안 바꾸고 후처리만 있었는데 이 차이가 **0.0237**에서 **0.0137**로 줄었다는 겁니다. 분할 방식을 네 가지로 가정해 시뮬레이션해봤지만 어느 것도 이 축소를 설명하지 못했습니다. → **생각해볼 것**: 후처리(예측을 정수로 누르는 것)가 왜 두 반쪽의 점수 차이를 줄이는가? 여기에 우리가 놓친 구조가 있을 수 있습니다.

Q5 당장 시험해볼 것이 하나 남아 있습니다 — `n_od`

28일 창 안에 **같은 요일이 4번** 들어 있습니다. 그런데 그중 **실제로 영업한 날이 몇 번인지**를 모델에 안 알려주고 있습니다. 화담숲처럼 46%가 휴무인 곳은 4번 중 1~2번만 영업한 창이 흔한데, 모델은 그걸 "수요 감소"로 오해합니다.

같은 요일 중 영업일 수	0	1	2	3	4
필요한 보정 배율	1.92	1.76	1.34	1.18	0.98

배율이 **완전히 단조롭게** 줄어듭니다. 우연한 패턴이 아니라는 뜻이고, 평가 대상의 **28.6%**가 여기 해당합니다. 기존 피쳐로는 복원이 안 됩니다. 기대 개선은 +0.001~0.003 — 우리 측정 한계(0.002~0.003)에 걸쳐 있어서 판정이 애매하지만, 남은 유일한 후보입니다.

5-2. 어디가 틀렸는지 좁혀 들어가는 방법

위 질문들에 답하려면 "우리가 어디서 틀리는지"를 데이터로 좁혀야 합니다. 다행히 이 대회는 그게 정확하게 됩니다.

2-1의 평가식에서 $w_s \cdot |I_s| \cdot T_i$ 가 전부 실측 A만으로 정해지고 예측과 무관합니다. 그래서 점수를 이렇게 쓸 수 있습니다.

$$\text{Score} = \sum_c w_c \cdot (\text{그 칸의 벌점})$$

w_c 는 A만의 함수

→ 칸을 어떤 기준으로 나누든 각 조각의 기여를 정확히 더할 수 있다. 근사가 아니라 산수.

⚠ 그런데 함정이 있습니다 — 이번에 실제로 빠졌습니다

"벌점이 큰 곳"과 "우리가 고칠 수 있는 곳"은 다릅니다.

"가장 못하는 품목"을 뽑았더니 12개 중 6개가 단체 메뉴였습니다. "단체가 문제구나" 했는데, **창 정보를 아예 안 주고 품목 평균만 아는 바보 예측기**를 대조군으로 돌려보니:

	우리 모델	바보 예측기
단체 13품목	0.6405	0.6609
나머지 180품목	0.4735	0.5120

바보 예측기도 단체에서 똑같이 나빴습니다. 즉 단체가 나쁜 건 우리 잘못이 아니라 4장의 이론 하한이었고, 격차의 89%가 그것으로 설명됩니다.

→ 벌점이 큰 곳을 쫓으면 "원래 어려운 곳"으로 갑니다. 봐야 할 건 잔여(실제 벌점 - 그 칸의 하한)입니다.

더 날카로운 도구 — 오라클 분해

측을 하나 정하고, 그 측의 값별로 정답을 보고 최적 배율을 사후에 먹여봅니다. "이 측을 완벽히 알면 얼마나 좋았지나"를 재는 것이고, 피처를 만들어보지 않고도 상한선을 몇 초에 봅니다.

완벽히 알려준다면	겨울	봄	읽는 법
영업장별 그날 총 판매량	+0.1059	+0.1346	여기 안 쓴 정보가 있다
영업장별 그 주 총 판매량	-0.0814	-0.0243	이미 소진 (맞추면 오히려 손해)

n_od (Q5)가 살아남은 것도 이 방법이었습니다. 배율이 1.92 / 1.76 / 1.34 / 1.18 / 0.98로 완전히 단조였거든요.

판정 규칙

배율이 단조로우면 진짜 신호, 들쭉날쭉하면 잡음. 공휴일 측은 이 기준으로 졌습니다 — 이득의 86%가 특정 창 하나에서 나왔습니다.

5-3. 이 방법으로 바로 해볼 수 있는 것 둘

Q6 봄에 남은 0.03~0.05가 어디에 몰려 있는가?

이게 가장 결정적인 진단입니다. 4장에서 겨울은 하한에 도달했고 봄만 여지가 남았다고 했는데, 그 여지가 봄 전체에 고르게 퍼져 있는지 특정 시기에 몰려 있는지를 아직 모릅니다.

몰려 있다면 → 국소 처방이 가능하다 (예: 재개장 전후 2주)
퍼져 있다면 → 구조적 한계다. 접을 근거가 된다

봄에는 화담숲 재개장(3월 말)과 스키장 폐장이 겹칩니다. 여지가 그 전환 주간에 몰려 있다면 문제는 "예측이 어렵다"가 아니라 "우리가 전환을 못 알려주고 있다"가 되고, 그건 고칠 수 있는 종류입니다.

※ 참고로 `config.py` 의 화담숲 개장일이 3/20으로 박혀 있는데 실제 개장은 3/29~31입니다. 9~11일 틀렸고, "영향이 작다"고 판단해 그냥 뒀던 항목입니다.

비용: 저장된 예측만 사용 · 학습 0회 · 제출 0회 · 10분 내외

Q7 창이 급변할 때 우리가 한쪽으로 체계적으로 틀리는가?

가설: 트리는 본질적으로 평균을 내는 기계라 추세의 끝을 외삽하지 못하고 안쪽으로 당깁니다. 그러면 오르는 창은 과소예측, 내리는 창은 과대예측이 체계적으로 나와야 합니다.

우리 피처에 `w_trend` (창의 추세)가 들어 있긴 합니다. 하지만 피처가 있다는 것과 모델이 그걸 충분히 쓴다는 것은 다릅니다. 5-2의 도구로 바로 확인할 수 있습니다 — 창의 추세를 몇 구간으로 나누고 구간별 최적 배율을 봅니다.

급하강 창 ... 완만 ... 급상승 창
배율이 단조롭게 증가하면 → 진짜 신호, 피처 또는 보정 후보
들쭉날쭉하면 → 잡음, 폐기

그리고 이건 Q6과 이어집니다. 전환기(봄)가 정확히 창이 급변하는 시기이기 때문입니다. Q6에서 "여지가 전환 주간에 몰려 있다"가 나오면 Q7이 그 처방이 될 수 있습니다.

비용: 학습 0회 · 제출 0회 · 10분 내외

다만 — 분해를 많이 하면 반드시 뭔가 "발견"됩니다

9-c에서 "품목 수가 적은 영업장일수록 개선이 크다"는 예쁜 단조 패턴을 찾고 가설 확인이라 적었는데, 설계를 바꾼 9-e에서 그 패턴이 통째로 무너졌습니다.

그리고 우리는 독립 검증 구간이 겨울·봄 둘뿐입니다(2-4 참고). 잘게 쪼갤수록 조각당 표본이 줄어 잡음이 커집니다.

→ 쪼갤 축을 미리 정하고 그것만 봅니다. 그리고 발견한 패턴은 두 구간 모두에서 재현될 때만 믿습니다.

6. 정리

항목	내용
현재 성적	Private 0.43912 · 1등 0.437과 0.0021 차이 · 시작 대비 +0.02156
개선의 출처	후처리 83% / 모델 17%
남은 여지	이론상 0.02~0.03 (필요한 0.0021의 10~15배)
문제	그 여지가 "그날" 속에 있고, 그건 날씨로 보이며, 규칙상·구조상 접근 불가
달한 축	하이퍼파라미터 · 앙상블 · 모델 구조 분리 · 학습 가중치 · 후처리 추가 최적화 · 품목별 보정
바로 할 수 있는 것	Q6 봄의 여지 위치 · Q7 창 추세 방향 — 둘 다 학습 0회 · 제출 0회 · 각 10분
실행 대기	<code>n_od</code> 피쳐 1개 (Q5) — 20시드 재학습 1회
같이 생각할 것	Q1 날씨 대체 신호 · Q2 봄이 다른 이유 · Q3 가중 구조 · Q4 미해결 현상

다음 한 걸음을 고른다면 — Q6

Q6은 "더 할 게 있나 없나"에 직접 답하는 진단입니다. 여지가 특정 시기에 몰려 있으면 표적이 생기고, 고르게 퍼져 있으면 접을 근거가 됩니다. 어느 쪽이 나와도 다음 결정이 정해집니다. 그리고 학습도 제출도 필요 없어서 실패 비용이 사실상 0입니다.

이 대회에서 배운 것 한 가지만 남긴다면

"모델을 좋게 만드는 것"과 "점수를 올리는 것"은 다른 일이었습니다.

우리가 얻은 개선의 83%는 모델을 한 번도 다시 학습하지 않고 나왔습니다. 전부 평가식이 무엇을 벌하고 무엇을 봐주는지를 들여다본 결과였습니다 — 0인 칸은 채점하지 않는다는 것, 벌점이 비율에 대칭이라는 것, 실측이 정수라는 것.

반대로 내부 검증 점수를 보고 판단한 것은 네 번 시도해서 네 번 다 손해였습니다.

상세 수치와 실험 이력은 `experiments/log.md`에 있습니다. 제출 15건의 Public/Private 점수, 폐기한 축과 그 근거, 방법론 규칙 14개가 기록돼 있습니다.